



LARGE LANGUAGE MODELS

GIORGIO GAMBOSI


DIPARTIMENTO DI INGEGNERIA DELL'IMPRESA "MARIO LUCERTINI"

Reti neurali


In una rete neurale il passaggio da rappresentazione iniziale a rappresentazione finale avviene per mezzo di una sequenza di trasformazioni da rappresentazione a rappresentazione

Tutte le trasformazioni sono effettuate mediante funzioni parametriche, con valori dei parametri da apprendere

Representation learning e reti neurali



Più sinteticamente...




Più sinteticamente...




**Rappresentazione
iniziale**

**Rappresentazione
finale**

Più in dettaglio...



Deep learning




X

Molti layer (trasformazioni di rappresentazione)

Parametri

- Possono essere pochi: modello semplice


Classificatore lineare




Parametri

- Possono essere molto numerosi

Rete neurale “profonda”




CNN




CNN

ResNet18 - Structural Details														
#	Input Image			output			Layer	Stride	Pad	Kernel		in	out	Param
1	227	227	3	112	112	64	conv1	2	1	7	7	3	64	9472
	112	112	64	56	56	64	maxpool	2	0.5	3	3	64	64	0
2	56	56	64	56	56	64	conv2-1	1	1	3	3	64	64	36928
3	56	56	64	56	56	64	conv2-2	1	1	3	3	64	64	36928
4	56	56	64	56	56	64	conv2-3	1	1	3	3	64	64	36928
5	56	56	64	56	56	64	conv2-4	1	1	3	3	64	64	36928
6	56	56	64	28	28	128	conv3-1	2	0.5	3	3	64	128	73856
7	28	28	128	28	28	128	conv3-2	1	1	3	3	128	128	147584
8	28	28	128	28	28	128	conv3-3	1	1	3	3	128	128	147584
9	28	28	128	28	28	128	conv3-4	1	1	3	3	128	128	147584
10	28	28	128	14	14	256	conv4-1	2	0.5	3	3	128	256	295168
11	14	14	256	14	14	256	conv4-2	1	1	3	3	256	256	590080
12	14	14	256	14	14	256	conv4-3	1	1	3	3	256	256	590080
13	14	14	256	14	14	256	conv4-4	1	1	3	3	256	256	590080
14	14	14	256	7	7	512	conv5-1	2	0.5	3	3	256	512	1180160
15	7	7	512	7	7	512	conv5-2	1	1	3	3	512	512	2359808
16	7	7	512	7	7	512	conv5-3	1	1	3	3	512	512	2359808
17	7	7	512	7	7	512	conv5-4	1	1	3	3	512	512	2359808
	7	7	512	1	1	512	avg pool	7	0	7	7	512	512	0
18	1	1	512	1	1	1000	fc					512	1000	513000
Total													11,511,784	

Transformer



GAN




Sempre più parametri

Number of parameters in notable artificial intelligence systems

Our World
in Data

Parameters are variables in an AI system whose values are adjusted during training to establish how input data gets transformed into the desired output; for example, the connection weights in an artificial neural network.



Source: Sevilla et al. (2023)

Note: Parameters are estimated based on published results in the AI literature and come with some uncertainty. The authors expect the estimates to be correct within a factor of 10.

OurWorldInData.org/artificial-intelligence • CC BY

Considerazioni

- La funzione di costo è arbitraria, ma “ragionevole”
 - minimizzazione complessiva differenze tra predizioni e valori corretti
 - minimizzazione numero errori
- Valutazione della qualità della predizione mediante funzione di costo predefinita
 $C : \text{predizione} \times \text{valore corretto} \mapsto R$

Introduzione coefficienti e funzione di rischio

Considerazioni

- Dato che i valori corretti sono fissati e le predizioni sono funzione dei parametri del modello, la funzione di costo può essere vista come $C' : \text{parametri} \mapsto R$
- Il problema diventa la minimizzazione di C' nel dominio dei parametri

Limitazioni di fondo

Utilizzo di un modello

- rappresentazione semplificata della realtà
 - alcune variabili
 - soltanto valori misurabili
- relazione matematica tra variabili considerate e predette

Assunto induttivo

- Il modello predice “fedelmente” rispetto ai dati disponibili



Il modello predice al meglio qualunque dato futuro

Ipotesi nascoste

E' possibile quantificare la qualità predittiva del modello



Ciò che si intende predire è effettivamente quantificabile in modo efficace

Ipotesi nascoste

Il “modello del mondo” utilizzato è sufficientemente fedele



Le variabili disponibili descrivono adeguatamente tutte le informazioni utili alla predizione

Ipotesi nascoste

La verifica della qualità è sufficientemente
esaustiva



Non esistono, o sono estremamente rari, casi in cui
la predizione è “molto” scorretta

Ipotesi nascoste

Le predizioni non sono “biased”



Le predizioni successive, condizionate da un qualunque valore di una qualunque variabile, non devono differire statisticamente dai valori corretti, condizionati allo stesso modo

Ipotesi nascoste

I dati disponibili non sono “biased”




La distribuzione dei valori corretti, condizionati a qualunque valore su qualunque variabile, non deve differire statisticamente dalla popolazione generale: il campione deve essere “unbiased”

Foundation models

Machine learning: invece di dover specificare come risolvere un problema, il metodo di soluzione **emerge** dai dati

Deep learning: invece di dover specificare come rappresentare i dati, la rappresentazione più efficace **emerge** da essi

Foundation models: invece di dover specificare esempi di risoluzione di un problema, le funzionalità **emergono** dai dati




Foundation models

Modelli “di base” incompleti (e generali).

Utili come base comune su cui costruire modelli per task specifici mediante una fase di adattamento

- Transfer learning
- Huge datasets
- Semi-supervised learning

Foundation models




Large Language Model

Un large language model (in italiano "modello di linguaggio di grande dimensione") è un tipo di modello di intelligenza artificiale utilizzato nell'elaborazione del linguaggio naturale (NLP). Questi modelli utilizzano tecniche di apprendimento automatico per analizzare grandi quantità di dati testuali e imparare a generare testo in modo autonomo.

I large language model sono in grado di comprendere il significato del linguaggio umano, la grammatica e la sintassi, nonché di riconoscere il contesto e la semantica delle parole. In questo modo, sono in grado di generare testo in modo simile a come lo farebbe un essere umano, producendo testi coerenti e naturali.

Uno dei più famosi large language model è GPT (Generative Pre-trained Transformer) sviluppato da OpenAI, che utilizza una rete neurale a trasformatori per generare testo in modo autonomo. Questi modelli hanno molteplici applicazioni, come la generazione di testo per chatbot, assistenti vocali, traduzione automatica, riassunto di testo e altro ancora.

Large Language Model



Large Language Model

Un language model non è altro che una distribuzione di probabilità di parole condizionata da una sequenza di altre parole (precedenti)

$$p(w \mid \langle w_0, w_1, \dots, w_m \rangle)$$

$$p(\text{'gatto'} \mid \text{'prima ho visto il mio'})$$

$$p(\text{'cane'} \mid \text{'prima ho visto il mio'})$$

$$p(\text{'amico'} \mid \text{'prima ho visto il mio'})$$

⋮

$$p(\text{'nuovo'} \mid \text{'prima ho visto il mio'})$$

Language Model

$$p(w \mid \langle w_0, w_1, \dots, w_m \rangle)$$

utilizzata per generare iterativamente frasi

la generazione è stocastica (sampling sulla distribuzione)

I _____


Large Language Model

$$p(w \mid \langle w_0, w_1, \dots, w_m \rangle)$$

è molto complessa (ha molti parametri)


complessità necessaria per modellare la ricchezza del linguaggio naturale

viene calcolata per mezzo di una rete neurale




Numero di parametri

Parameters of transformer-based language models



Un po' più in dettaglio




Un po' più in dettaglio


Model Name	n_{params}	n_{layers}	d_{model}	n_{heads}	d_{head}	Batch Size	Learning Rate
GPT-3 Small	125M	12	768	12	64	0.5M	6.0×10^{-4}
GPT-3 Medium	350M	24	1024	16	64	0.5M	3.0×10^{-4}
GPT-3 Large	760M	24	1536	16	96	0.5M	2.5×10^{-4}
GPT-3 XL	1.3B	24	2048	24	128	1M	2.0×10^{-4}
GPT-3 2.7B	2.7B	32	2560	32	80	1M	1.6×10^{-4}
GPT-3 6.7B	6.7B	32	4096	32	128	2M	1.2×10^{-4}
GPT-3 13B	13.0B	40	5140	40	128	2M	1.0×10^{-4}
GPT-3 175B or “GPT-3”	175.0B	96	12288	96	128	3.2M	0.6×10^{-4}

Fig-2: Details of variants of the GPT-3 model


Un po' più in dettaglio




Un po' più in dettaglio



Semi supervised learning



Dimensione dataset



Fine tuning

Fine-tuning

The model is trained via repeated gradient updates using a large corpus of example tasks.



da <https://arxiv.org/pdf/2005.14165.pdf>

Fine tuning

I coefficienti del modello sono modificati in modo supervisionato


Esempi relativi al task desiderato

Migliora le prestazioni del modello rispetto al task finale

Necessità di dataset di esempi


RLHF

In Chatbot, utilizzo continuo dei feedback dagli utenti per aggiornare il modello




RLHF

Integrazione di metodi di Reinforcement learning (RL from Human Feedback)



Evoluzione



Prompting

Un LLM è interrogato fornendo un testo (prompt) che specifica un'istruzione per l'esecuzione di un task

Il LLM fornisce una risposta, completando la prompt, senza ulteriore apprendimento e fine tuning

La prompt può consistere di uno o più esempi di coppie input-output del task in questione

Few-one-zero shot

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1  Translate English to French:  ← task description
2  sea otter => loutre de mer    ← examples
3  peppermint => menthe poivrée ←
4  plush girafe => girafe peluche ←
5  cheese => .....            ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
1  Translate English to French:  ← task description
2  sea otter => loutre de mer    ← example
3  cheese => .....             ← prompt
```

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1  Translate English to French:  ← task description
2  cheese => .....             ← prompt
```

Capacità emergenti in LLM

La capacità di rispondere a prompts con esempi mostra la presenza di abilità rispetto a task su cui non c'è stato addestramento esplicito supervisionato

La capacità è tipicamente “emergente” in quanto non presente in modelli più piccoli e appare in modelli sufficientemente grandi

Prestazioni quasi random fino a una certa dimensione (soglia)

Poi, aumento significativo

Transizione di fase

Pappagalli stocastici

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?



Emily M. Bender^{1*}, Timnit Gebru^{2*},
Angelina McMillan-Major¹, Shmargaret Shmitchell³

¹University of Washington ²Black in AI ³The Aether
*These authors contributed equally.

Gli LLM sono soltanto dei “pappagalli stocastici”, algoritmi che usano la randomizzazione per mescolare, in modo attendibile, frasi prodotte da persone reali.

I linguaggi naturali sono sistemi di segni, composti da forma e significato. Gli LLM hanno accesso e sono basti sulla sola forma, senza significato.

Pappagalli stocastici

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?



Emily M. Bender^{1*}, Timnit Gebru^{2*},
Angelina McMillan-Major¹, Shmargaret Shmitchell³

¹University of Washington ²Black in AI ³The Aether
*These authors contributed equally.

we call on the field to recognize that applications that aim to believably mimic humans bring risk of extreme harms. Work on synthetic human behavior is a bright line in ethical AI development, where downstream effects need to be understood and modeled in order to block foreseeable harm to society and different social groups

Problematiche generali

Istanziare un LLM richiede risorse importanti

Elaborazione massiva

Costi ambientali:

energia necessaria per training e conseguente emissione di CO₂

distribuzione costi/benefici

Problematiche generali

Istanziare un LLM richiede risorse importanti


Grandi dataset

Valutazione della qualità del dataset

qualità del dataset al fine di evitare bias e comportamenti
inopportuni

questioni di copyright

Problematiche generali



Problematiche generali

Istanziare un LLM richiede risorse importanti

Chi si può permettere la ricerca e la produzione?

Ricerca concentrata in poche sedi

Ruolo delle grandi aziende e della
ricerca industriale

Trasparenza, verificabilità, riproducibilità

Problematiche generali

Aspetti economici

aumento produttività

impatto sul mercato del lavoro

skilled/unskilled

Problematiche generali

Affidabilità dei sistemi e HCI

Tendenza a mis-interpretare gli output del sistema da parte dell'utente

produzione di testo realistico e attinente

produzione di affermazioni vere

hallucination

Problematiche generali

Affidabilità dei sistemi e HCI

evitare aspettative e utilizzo improprio degli strumenti

NON SONO ORACOLI

OpenAI Statement

AGI has the potential to give everyone incredible new capabilities; we can imagine a world where all of us have access to help with almost any cognitive task, providing a great force multiplier for human ingenuity and creativity.

On the other hand, AGI would also come with serious risk of misuse, drastic accidents, and societal disruption. Because the upside of AGI is so great, we do not believe it is possible or desirable for society to stop its development forever; instead, society and the developers of AGI have to figure out how to get it right.

Pause Giant AI Experiments: An Open Letter

“We call on all AI labs to immediately pause for at least 6 months the training of AI systems more powerful than GPT-4. This pause should be public and verifiable, and include all key actors. If such a pause cannot be enacted quickly, governments should step in and institute a moratorium.

AI labs and independent experts should use this pause to jointly develop and implement a set of shared safety protocols for advanced AI design and development that are rigorously audited and overseen by independent outside experts. These protocols should ensure that systems adhering to them are safe beyond a reasonable doubt.”

Open source

Necessità di trasparenza ed apertura dei sistemi

Sviluppo cooperativo

Specificità del contesto:

Architettura del modello

+

Valori dei parametri

Dataset utilizzati per l'apprendimento

Procedure e tecniche per il training

Open source

Sviluppo e condivisione di modelli; condivisione dei parametri (o dataset)

Adattamento delle procedure per lo sviluppo OS

A Call to Build Models Like We Build Open-Source Software

Colin Raffel

December 8th, 2021

colinraffel.com/blog

Bibliografia minima

“On the Dangers of Stochastic Parrots”

“Ethical and social risks of harm from Language Models”

“A Survey of Large Language Models”

“On the Opportunities and Risks of Foundation Models”,

“Attention is all you need”

“Taxonomy of Risks posed by Language Models”

“A Survey on in-context Learning”

“Language Models are Few-Shot Learners”



“GPT-4: "GPT-4 Technical Report”

“Finetuned Language Models Are Zero-Shot Learners”

“Deep Reinforcement Learning from Human Preferences”

“Emergent Abilities of Large Language Models”

Bibliografia minima



Bibliografia minima

