

QUESTI LLM, MA CHE SONO?

UNA SEMPLICE(?) INTRODUZIONE



MA CHE COSA VORREMMO?

Un sistema che risponde alle domande che gli facciamo su qualunque cosa, fornendoci risposte articolate, come se fosse un interlocutore umano

SE DOVESSIMO REALIZZARLO...

Il sistema data una domanda (o una frase)
dovrebbe produrre una risposta “corretta”

Domanda



Risposta
“corretta”

Corretta, in che senso?

- dal punto di vista dei contenuti
- dal punto di vista sintattico



COME SI POTREBBE REALIZZARE?

Dovrebbe:

1. Capire di cosa si sta parlando (sa che cosa è uno studente, cosa è una lezione, cosa è un'università, e così via) → ha un modello preciso e esaustivo del mondo
2. Essere in grado di “ragionare” nel senso di derivare conseguenze da premesse (derivare che se uno studente assiste alla lezione “probabilmente” si chiarisce le idee)
3. Essere in grado di dialogare sia comprendendo le domande poste in linguaggio naturale che costruendo delle risposte, sempre in linguaggio naturale, che siano corrette sia dal punto di vista dei contenuti (nel senso che comunicano l'informazione dedotta dal ragionamento fatto) che sintatticamente (sono frasi corrette dell'italiano)



Affascinante!

Solo che al momento non si sa come costruire un sistema del genere.
Tropo difficile, per quanto si sa fare al momento

E allora, come si potrebbe fare?





Idea!

Costruire un sistema che,
visto da fuori,
si comporta come
il precedente

“Sembra capire” quel che
gli viene chiesto e risponde
come risponderebbe l’altro



**IF IT LOOKS
LIKE A DUCK,
SWIMS LIKE A
DUCK, AND
QUACKS LIKE
A DUCK, THEN
IT PROBABLY
IS **A DUCK.****



Abbiamo definito un nuovo obiettivo, più praticabile (forse)

Domanda



Risposta
“plausibile”

Ecco: ma come si potrebbe costruire un sistema come questo?

Prima questione

- Ma come potrebbe fornire risposte plausibili senza capire di cosa si sta parlando?



Idea!



Osservando come si risponde di solito!


In che senso “osservando”? Osservando cosa?

Osservando tutto quello che è stato scritto, e cosa è stato scritto di solito dopo la domanda posta


E osservando da dove tutto quello che è stato scritto?

Da Internet, che contiene milioni di documenti, libri e testi

Ma come potremmo fare per fargli produrre una frase di risposta, data la domanda?



Una risposta è lunga: potremmo produrla una parola alla volta...



Non vogliamo produrre sempre la stessa parola, per cui ...



Estraiamo a sorte!



Distribuzione di probabilità sulle parole

4 valori: p , p , p , p

3 indipendenti, in quanto $p+p+p+p=1$

$p = P(\text{prossima parola} = \text{red})$

$p = P(\text{prossima parola} = \text{purple})$


$p = P(\text{prossima parola} = \text{yellow})$

$p = P(\text{prossima parola} = \text{blue})$

Modello di linguaggio

Come costruisco la risposta?

Estraggo le parole della risposta dall'urna, una dopo l'altra



Introduciamo un po' di contesto

Il contesto è dato dalla parola precedente



il modo di produrre la prossima parola dipende dall'ultima

4 urne (una per ogni parola precedente)



Distribuzione di probabilità sulle parole, condizionata dalla parola precedente

$P(\text{prossima parola} = \bullet \mid \text{ultima parola} = \bullet)$

$4 \times 4 = 16$ valori,


$4 \times 3 = 12$ indipendenti

Ogni parola è generata pescando nell'urna corrispondente alla parola precedente

Estendiamo il contesto: la prossima parola dipende dalle ultime 12

Le ultime 12 parole precisano un contesto (quello di cui si sta parlando)

Distribuzione di probabilità sulle parole, condizionata dalla
sequenza delle 12 parole precedenti




$P(\text{prossima parola} = \text{purple} \mid \text{ultime 12 parole} = \text{red, yellow, blue, purple, ...})$

4^{12} contesti diversi (sequenze possibili delle ultime 12 parole)

4^{12} urne diverse

Quindi, come viene prodotta la risposta?



Partiamo dalla sequenza delle parole della domanda (ad esempio ne consideriamo 12)

Estraiamo la prima parola della risposta dall'urna corrispondente

Consideriamo la sequenza di 12 parole ottenuta scartando la prima parola dalla sequenza vecchia e mettendo la parola estratta come ultima

Estraiamo una nuova parola della risposta dall'urna corrispondente

In questo modo, a partire dalla domanda si può produrre, parola dopo parola, una risposta

Però...

Per far questo, bisogna conoscere come è fatta l'urna **per ogni possibile sequenza di 12 parole**



Problema



Sono $4^{12} = 16.777.216$ urne

Non possiamo memorizzarle tutte: sono
 $3 * 16.777.216 = 50.331.648$ valori
in { ●, ●, ●, ● }



In realtà è molto peggio: in ChatGPT ci sono circa
50000 parole diverse (non 4) e la sequenza è lunga
32000 parole (non 12)



Come possiamo fare? Non possiamo annotarci tutte le possibilità.



Idea!

Definiamo un procedimento (un algoritmo) che ci dice come, data una sequenza di 32K parole, possiamo calcolare come è fatta l'urna da cui estrarre la prossima parola (50000 probabilità diverse)



Una cosa da Fantascienza!



Algoritmo HAL9000 (visto da fuori)



Bella idea: ma come faccio a fargli prevedere la prossima parola “giusta”?

Open the box: HAL9000 visto da dentro

50000



$p(\text{pink})$
 $p(\text{purple})$
 $p(\text{yellow})$
 $p(\text{blue})$

...

$p(\text{red})$

All'interno di HAL9000 ci sono un sacco di pulsanti e manopole che determinano come funziona esattamente



PULSANTI E MONOPOLE...

Spingo un pulsante o ruoto una manopola e HAL9000 si comporta diversamente




Fornisce una distribuzione diversa della prossima parola, dato lo stesso contesto



Problema

Come scegliamo la posizione di pulsanti e manopole?

Prendo quella che fa sì che le parole generate siano il più possibile quelle giuste, nei testi che consideriamo come esempi!



Problema



ChatGPT ha 1.5 miliardi di manopole!

Come si possono trovare tutti quei valori?



Idea! Andiamo un passo alla volta.



Confrontiamo la parola fornita dall'algoritmo con quella giusta




Se è quella giusta non va cambiato nulla

Se è sbagliata va cambiato qualcosa

Se è tanto sbagliata va cambiato tanto



Una cosa magica!



1.5 miliardi di valori

Utilizziamo un altro procedimento: Gandalf ci dice, per ogni coppia (parola prevista – parola effettiva):

- Quanto è sbagliata la previsione
- Di quanto dobbiamo modificare la posizione di ogni manopola (il valore dei parametri) per migliorare almeno un po' le predizioni

E come è fatto quest'altro algoritmo? Sembra magia!



In realtà è semplice, ma non abbiamo tempo per raccontarlo.

Suggerimento: c'entrano le derivate...



Quindi, questa è l'idea:

- abbiamo un algoritmo (HAL9000) che usiamo per prevedere la prossima parola
- HAL9000 ha tanti parametri (manopole) che ne modificano il comportamento
- consideriamo una alla volta parti di testi che conosciamo per fargli fare una predizione
- confrontiamo il valore predetto e quello corretto, che conosciamo; un altro algoritmo (Gandalf il Grigio) ci dice come modificare la posizione delle monopole per migliorare il funzionamento di HAL9000
- modifichiamo la posizione delle monopole




Facciamo in modo che HAL9000 si comporti bene senza aver spiegato cosa vuol dire **bene**



Lo facciamo solo sulla base di (tanti) esempi



Attenzione, però, ci sono molte questioni aperte




Come rappresentiamo
C'è un modo più



HAL9000 ha tanti parametri, ma anche una struttura
Come la scegliamo?

Possiamo fare altro per migliorare
ulteriormente le risposte?



A Gandalf servono tanti esempi da considerare
(570 GB di testo per ChatGPT).

Come eseguire tutti i passi abbas



Problema: come pensare
procedimenti efficienti?



Su un singolo computer occorrerebbero alcuni secoli...

Problema: Come far collaborare tra loro migliaia di computer?



Tutto questo deve essere implementato in un programma...

Problema: Come fare per ottenere un programma che fa
esattamente quello che si vorrebbe?



Tutto questo (e altro) è stato fatto

E chi ha costruito tutto ciò?

un team di informatici

